

INTELIGENCIA ARTIFICIAL CURSO DE PROCESAMIENTO DEL LENGUAJE NATURAL: TOKENIZACIÓN

CÓDIGO ESPINOZA



Tokenización

- Dividir el texto en tokens
- Los tokens son las unidades individuales de un texto
- Por ejemplo, las palabras son tokens en un proceso de tokenización basado en palabras.

Función split

- [Ver Notebook](#)

Comparación de la tokenización moderna y antigua

- Solía ser tan simple
- La tokenización moderna es mucho más sofisticada

Diferentes perspectivas para abordar el tema

- Basada en palabras (casa, perro, etc.)
- Basada en caracteres (a, d, 4, #, etc.)
- Basada en sub-palabras (automóvil => auto, móvil)

Relevancia del volumen de datos para el aprendizaje de modelos

- El volumen de datos es crucial para el aprendizaje de modelos

Manejo de los casos de las letras (mayúsculas y minúsculas)

- La palabra "Hola" no es la misma que "hola" para una máquina
- Ej; solución: ver notebook