

INTELIGENCIA ARTIFICIAL CURSO DE PROCESAMIENTO DEL LENGUAJE NATURAL: MÉTODO TF-IDF

CÓDIGO ESPINOZA



Introducción a TF-IDF

- Term frequency (TF) e Inverse document frequency (IDF)
- ¿Qué es el método TF-IDF?

Problemas con el método de conteo

- No toma en cuenta la relevancia de las palabras
- TF-IDF reduce el peso de las palabras comunes y aumenta el peso de las palabras que no se utilizan con frecuencia

Stop words

- Palabras comunes como si, la, el, más, etc.
- Si se dejan en el texto, pueden sesgar el análisis hacia las palabras más comunes
- Eliminar las stop words puede hacer que los algoritmos sean más precisos y rápidos, ya que hay menos palabras a procesar

Ambigüedad y especificidad de las stop words dependiendo de la aplicación

- No todas las palabras comunes son stop words en todas las situaciones
- Por ejemplo, "no" podría ser una stop word en muchos contextos, pero no en el análisis de sentimientos, donde podría ser una palabra clave

Descripción de cómo funciona TF-IDF

- TF-IDF funciona al asignar un puntaje a cada palabra en un documento en función de su frecuencia en ese documento (TF) y su frecuencia en todos los documentos (IDF).
- Cuanto más a menudo aparece una palabra en un solo documento, pero menos a menudo en todos los documentos, mayor es su puntaje TF-IDF.
- Las palabras que aparecen con más frecuencia en un documento pero raramente en otros documentos son más importantes

Formulación de TF-IDF y su justificación

- TF-IDF se calcula multiplicando dos componentes: TF e IDF.
- TF se calcula como el número de veces que aparece una palabra en un documento dividido por el total de palabras en ese documento
- IDF se calcula como el logaritmo del total de documentos dividido por el número de documentos que contienen la palabra
- $TF\text{-}IDF = TF(t, d) * IDF(t, D)$
- $TF(t, d) = (\text{Número de veces que el término } t \text{ aparece en el documento } d) / (\text{Total de términos en el documento } d)$
- $IDF(t, D) = \log_e(\text{Total de documentos en el corpus } D / \text{Número de documentos donde el término } t \text{ aparece})$